attrx

Характеристики товара — из текста карточки. Каждое значение с цитатой и уверенностью

Гибрид для каталога М.Видео: правила и словари закрывают ядро, NER — свободный текст, LLM — только остаток. На выходе канонические значения; сомнительное уходит модератору, а его правки пополняют словари.

КАРТОЧКА ИЗ ДАТАСЕТА · SKU 30056016 · БЕЗ КАТЕГОРИИ

Смартфон OPPO Reno5 Black (CPH2159) …оснащен 6,43-дюймовым безрамочным экраном… Емкость аккумулятора — 4310 мАч, поддерживается быстрая зарядка.

ATTRX · КАТЕГОРИЯ «СМАРТФОНЫ» — КЛАССИФИКАТОР

Бренд цитата «OPPO» · правила · принято	**OPPO**	1,00
Диагональ экрана цитата «6,43-дюймовым» · правила · принято	**6,43″**	0,96
Ёмкость аккумулятора цитата «4310 мАч» · правила · принято	**4 310 мА·ч**	0,97

ПРОБЛЕМА · ДЕНЬГИ

Нет характеристики — нет товара в фильтре, а значит и в выручке

Характеристика не заполнена → **Товар не попадает в фильтр и в выдачу** → **Меньше показов, кликов и заказов** → **Недополученный GMV**

56,5%

кликов из поиска — по запросам, где покупатель назвал атрибут; 24,9% — характеристику кроме бренда и модели

«игровые ноутбуки»	тип	88 336
«встраиваемые посудомоечные машины 45см»	ширина	75 371
«смартфоны samsung»	бренд	68 732
«телевизоры 55»	диагональ	61 792
«накопительные водонагреватели 50л»	объём	28 465
«iphone 17 pro max 512gb»	память	4 691
«холодильник черный»	цвет	2 172

Числа у полос — клики по точному запросу. Доли — разметка всех запросов словарём каталога (бренды, модели, значения, свойства); описательные запросы без значения не засчитаны — оценка снизу.

1 177 200
описаний карточек: название и текст продавца — вход решения

546 069
офферов каталога с характеристиками в 6 963 категориях — эталон

30 991 350
кликов из поиска, 1 397 078 уникальных запросов — вес «что ищут»

75%
карточек (880 632) без оффера и без кликов: есть только текст — холодный старт

77% / 23%
партнёры маркетплейса / М.Видео среди 241 355 карточек с эталоном

Деньги: дозаполненная характеристика → больше показов в фильтрах и атрибутной выдаче × CTR × конверсия × средний чек. CTR, конверсия и чек — данные М.Видео; эффект подтверждаем A/B по категориям.

Источники: архив кейса; доли спроса — `docs/EDA.md` §6 (`attrx traffic`); клики по запросам — `docs/checkpoint/demand_stats.py`; объёмы — `attrx prepare`

ДЛЯ КОГО · JOBS-TO-BE-DONE

Четыре роли, одна работа: товар должен находиться по характеристикам

Контент-менеджер каталога

Когда приходит партия карточек, хочу проверять только сомнительные значения — с цитатой перед глазами, чтобы за смену пропустить больше SKU и не пустить ошибку в фильтры.

ЧТО ДАЁТ ATTRX

- очередь «на проверку»: сначала то, что чаще ищут; с цитатой
- правка в один клик → синоним в словаре

МЕТРИКА РОЛИ

SKU в час на модератора; доля значений без ручной правки

Категорийный менеджер

Когда развиваю категорию, хочу видеть, каких фильтров не хватает и сколько поиска они теряют, чтобы закрывать дыры там, где ищут.

ЧТО ДАЁТ ATTRX

- заполненность атрибутов с весом поискового спроса
- новая категория — сразу с предложениями на проверку

МЕТРИКА РОЛИ

coverage обязательных атрибутов, взвешенный трафиком

Продавец маркетплейса

Когда загружаю ассортимент, хочу не заполнять десятки полей руками, чтобы товар быстрее прошёл модерацию и начал продаваться.

ЧТО ДАЁТ ATTRX

- характеристики из описания, которое продавец уже написал
- список того, чего в карточке нет

МЕТРИКА РОЛИ

доля карточек, принятых с первого раза; время до публикации

Поиск, рекомендации, матчинг

Когда строю фильтры, ранжирование и склейку одинаковых SKU, хочу полные канонические значения с уверенностью, чтобы выбрать порог под свою задачу.

ЧТО ДАЁТ ATTRX

- канон: единицы, синонимы, справочник
- confidence у каждого значения; API и батч

МЕТРИКА РОЛИ

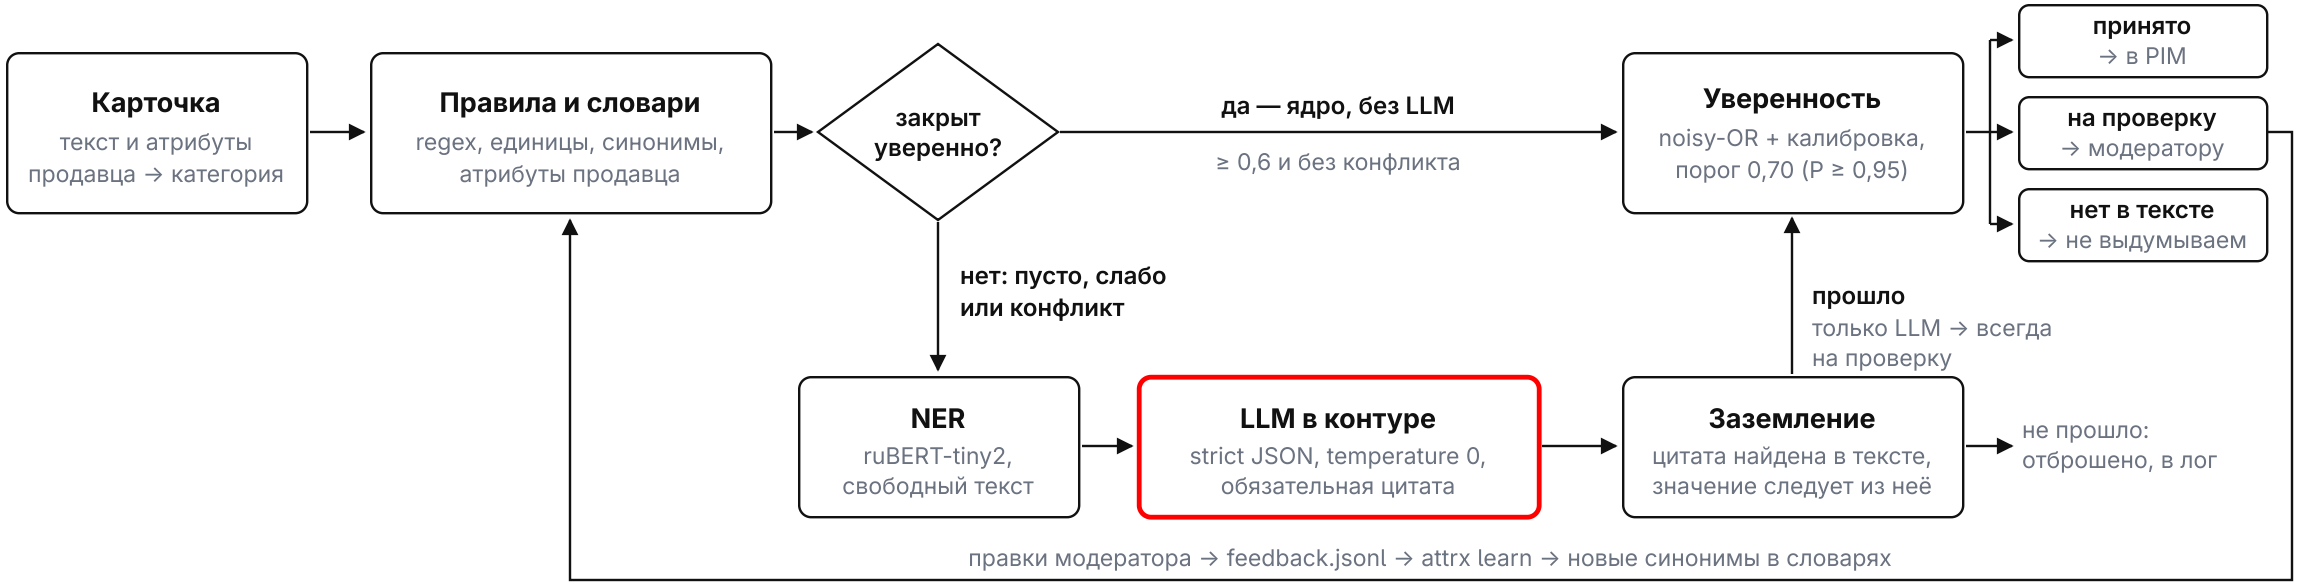
precision принятых значений; доля SKU в фильтрах

Единица ценности одна: верно заполненная характеристика, по которой ищут. attrx встаёт в PIM и модерацию через API и батч.

Работы ролей — гипотезы; проверяем интервью с контент-командой М.Видео ПЛАН

РЕШЕНИЕ · ГИБРИДНЫЙ ПАЙПЛАЙН

Ядро закрывают дешёвые правила. LLM — только для остатка и только с цитатой



Категория и правила
Без id категорию даёт классификатор (0,9998). Ядро — числа с единицами, 4 822 бренда каталога, цвета: CPU, бесплатно.

NER
ruBERT-tiny2 на разметке из каталога. Только слабые атрибуты — не портит то, что закрыли правила.

LLM
Холодный старт и остаток, только об упомянутых атрибутах. On-prem или РФ-облако, кэш, лимиты.

Заземление и порог
Решает проверка: цитата найдена в тексте, значение следует из неё; порог 0,70; одна LLM — на проверку.

Весь holdout, 23 391 карточка: правила F1 0,853 → + NER 0,858 (полнота по извлекаемому 0,918 → 0,927) при точности 0,954. На подвыборке 662: + LLM 0,849 = + NER 0,849 — значения одной LLM уходят на проверку.

Схема = `src/attrx/pipeline.py`; порог 0,70 — `config/calibration.json` (`attrx calibrate`); в хвост — уверенность < 0,6 (`LLM_ROUTE_THRESHOLD`); holdout — `submission/compare.json`

Нет цитаты — нет значения. Одна LLM — только на проверку

БРЕНД ПАМЯТЬ ЦВЕТ

Смартфон Xiaomi A5 3+64Gb зеленый (MZB0JRNRU)

Смартфон Redmi A5 3+64Gb зелёный... Ищете надёжный

и функциональный смартфон? [...]

Встроенная память: 64 ГБ — достаточно места... [...]

ДИАГОНАЛЬ

Дисплей: IPS, **диагональ 6,88 дюйма**, разрешение

1640x720... [...]

АККУМУЛЯТОР

Аккумулятор: 5200 мАч — длительное время работы...

— принято — на проверку · SKU 400633673, маркетплейс, категория — классификатор

АТРИБУТ	ЗНАЧЕНИЕ	УВЕРЕННОСТЬ	ИСТОЧНИК И ЦИТАТА	СТАТУС
Бренд	**Xiaomi**	1,00	правила · «Xiaomi»	● **принято**
Модель	**A5**	0,99	правила · «A5»	● **принято**
Встроенная память	**64 ГБ**	0,97	продавец + правила + NER + LLM · «3+64Gb»	● **принято**
Аккумулятор	**5 200 мА·ч**	0,92	продавец · «Аккумулятор: 5200 мАч»	● **принято**
Цвет	**зелёный**	0,97	правила · «зеленый»	● **принято**
Диагональ	**6,88″**	0,83	только LLM · «диагональ 6,88 дюйма»: выше порога, но второго источника нет	● **на проверку**

Holdout, подвыборка 662 карточки: 61 ответ LLM без опоры в тексте отброшен проверкой заземления (так, у iPhone цитата «Sage» не дала «серебристый»); из 71 значения одной LLM верны только 38% — поэтому они идут модератору, а не в каталог.

1 Схема
JSON Schema только с атрибутами категории; strict, temperature 0

2 Справочники
допустимые значения в промпте; вне справочника — отброс и «кандидат в справочник»

3 Цитата
фрагмент карточки обязателен для каждого значения

4 Заземление
цитата найдена в тексте (допуск на окончания), значение следует из неё; иначе — в лог

5 Только LLM
никогда не принимается сама; с продавцом, правилами или NER — по порогу 0,70

Петля: правка модератора → `feedback.jsonl` → `attrx learn` → синоним в словаре ЕСТЬ · значение LLM вне справочника → «кандидат в справочник» ЕСТЬ · правки → эталон и дообучение NER ПЛАН · экран модератора собирается из безопасных компонентов, значения — из результата, а не из ответа LLM ЕСТЬ

Реальная карточка train (SKU 400633673), прогон attrx 15.10: продавец + правила + NER + LLM (qwen3:4b-instruct, Ollama), калиброванная уверенность, порог 0,70; итоги LLM — `submission/REPORT.md` §4; правило — `pipeline.UNVERIFIED_ONLY`

КАК ИЗМЕРЯЕМ

Меряем то, что видит покупатель: каждый атрибут отдельно и с весом поискового спроса

МЕТРИКА	КАК СЧИТАЕМ	HOLDOUT · РЕЖИМ В СДАЧЕ	ЦЕЛЬ	АРТЕФАКТ
P / R / F1 по атрибуту	эталон каталога: vendor, model, param — по каждому атрибуту и категории	**P 0,954 · R 0,779 · F1 0,858**	P ≥ 0,95 у автопринятых, по каждому обязательному атрибуту	`metrics.json`
Извлекаемый recall	только по значениям, которые есть в тексте (их 83%)	**0,927**	≥ 0,90	`metrics.json`
Coverage	слоты каталога до → после; новое там, где каталог пуст, — не ошибка	**80,7% → 88,1% (+5 488); на проверку 10,8%**	рост без потери P ≥ 0,95	`metrics.json`
Traffic-weighted F1	вес = доля кликов категории × спрос на атрибут	**0,937 (потолок текста ≈ 0,96)**	≥ 0,90	`traffic.json`
Справедливость	F1 по сегментам: продавцы, размер категории, длина описания	**М.Видео 0,873 · партнёры 0,853; head 0,870 · tail 0,818**	продавцы ≤ 5 п.п., head / tail ≤ 10 п.п.	`segments.json`
Калибровка	уверенность 0,9 → верны 9 из 10; порог — под P ≥ 0,95	**ECE 0,019; при 0,70 точность принятых 0,954, принято 94%; слой 0,70–0,80 верен лишь на 57%**	ECE ≤ 0,05	`calibration.json`
Скорость и стоимость	карточек в секунду, доля вызовов LLM, ₽ на 1000	**LLM для 31% карточек, 3,3 с на вызов; ~1 500 карт./с на ядро без моделей**	LLM ≤ 20% карточек — пока 31%: не выполнено	`cost.json`

241 355
карточек с эталоном — характеристики, которые работают в фильтрах сайта

23 391
карточка holdout — весь сплит с эталоном; отчёт v2, исправления — только с dev; весь dev → весь holdout F1 0,859 → 0,858

83%
эталона есть в тексте: потолок micro-F1 ≈ 0,91 (holdout 0,858)

≈ 0,96
потолок traffic-weighted F1: спрос — на бренд и модель, а они почти всегда в тексте

Holdout — `submission/metrics.json`, `REPORT.md`; порог и калибровка выбраны на dev (`attrx calibrate`) и на holdout не подбирались. Цели — наши, сверяем с М.Видео

ВНЕДРЕНИЕ И ЭКОНОМИКА

В прод — через тень: автопринятие только выше порога, LLM внутри контура

ШАГ 0
Офлайн-оценка
Holdout эталона, разбор ошибок по атрибутам и сегментам.

Гейт: P ≥ 0,95 у автопринятых

ШАГ 1
Тень, 2–4 недели
Пишем предсказания рядом, не в каталог; сверяем с правками модераторов, калибруем порог по категориям.

ШАГ 2
Автопринятие
Выше порога — в PIM в топ-категориях по трафику; остальное — в очередь. Выборочный аудит каждый день.

ШАГ 3
Все категории
Холодный старт через LLM со статусом «на проверку»; правки дообучают NER и словари.

Интеграция с PIM. `POST /api/extract/batch` (до 1000 карточек) или `attrx extract` по выгрузке. Принятое — запись в PIM, «на проверку» — в очередь модерации.

Мониторинг и откат ЕСТЬ. `attrx monitor`: доля «на проверку» и «нет в тексте» по категориям, PSI категорий, доля вызовов LLM → алерт с действием. Выборочный аудит — в пилоте; precision ниже гейта — категория возвращается в тень.

Данные не покидают контур. LLM — любой OpenAI-совместимый endpoint: vLLM / Ollama on-prem, GigaChat / YandexGPT без VPN. Без LLM работают правила, словари и классификатор.

Скорость. Правила — ~1 500 карточек/с на ядро, с NER — 421 на GPU (весь holdout, медиана 3 замеров). LLM — 3,3 с на вызов, поэтому хвост в проде — асинхронно ПЛАН.

Стоимость 1000 карточек

$$C_{\text{гибрид}} = 1000 \cdot (c_{\text{CPU}} + p_{\text{LLM}} \cdot c_{\text{LLM}})$$

$$C_{\text{LLM на всё}} = 1000 \cdot c_{\text{LLM}}$$

$$c_{\text{LLM}} = T_{\text{вх}} \cdot P_{\text{вх}} + T_{\text{вых}} \cdot P_{\text{вых}}$$

$$C_{\text{гибрид}} / C_{\text{LLM на всё}} \approx p_{\text{LLM}}, \text{ так как } c_{\text{CPU}} \ll c_{\text{LLM}}$$

p_{LLM} — доля карточек, где гибрид зовёт LLM (holdout)	**31%**
Токены и время вызова (qwen3:4b-instruct, GTX 1060)	**969 / 52 · 3,3 с**
Гибрид, ₽ за 1000: своя GPU · GigaChat Lite · YandexGPT Lite	**0,83 · 20,6 · 63,2**
«LLM на каждую карточку», ₽ за 1000: те же	**5,6 · 84,6 · 260,2**
Повторный прогон той же карточки	**0 ₽, кэш**

API: `src/attrx/api/app.py` · замеры LLM и тарифы — `docs/LLM.md` §5–6, `config/llm_prices.yaml`, расчёт — `src/attrx/llm/cost.py`; скорость правил — `docs/EVALUATION.md` §8

ОТЛИЧИЯ

Почему не «LLM на каждую карточку»

КРИТЕРИЙ	LLM НА КАЖДУЮ КАРТОЧКУ	ATTRX — ГИБРИД
Стоимость	вызов на каждую карточку, на всех атрибутах	LLM только для остатка — 31% карточек; в 4–7 раз дешевле, кэш, лимиты
Галлюцинации	значение принимается как есть	цитата, заземление, справочник, калиброванный порог; значение одной LLM — только на проверку
Объяснимость	«так ответила модель»	у каждого значения цитата, источник и уверенность
Без LLM и сети	не работает	правила, словари и классификатор категории работают без LLM и сети
Воспроизводимость	ответы плавают между запусками	правила детерминированы; LLM — temperature 0 и кэш
Оценка	десятки карточек, проверенных вручную	эталон каталога: 241 355 карточек; веса по 30,99 млн кликов
Хвост и продавцы	провалы не видны	метрики по сегментам; holdout: М.Видео 0,873 · партнёры 0,853, head 0,870 · tail 0,818
Развитие	переписывать промпт	правки модераторов → словари; NER учится на эталоне

Эталон из каталога ЕСТЬ
характеристики, которые уже работают в фильтрах сайта

Веса спроса ЕСТЬ
какие атрибуты ищут в каждой категории — из реальных кликов

Разметка даром ЕСТЬ
NER обучен на 230 866 значениях каталога, найденных в тексте

Словари из данных ЕСТЬ
4 822 бренда каталога с транслитом: «Атлант» ~ ATLANT

Generative UI ЕСТЬ
экран модератора собирается из безопасных компонентов

ЕСТЬ — в репозитории сейчас; ПЛАН — до 23.10. NER: `docs/NER.md`, словари: `attrx build-dicts`

ПЛАН И РИСКИ

До 23.10: честные метрики на holdout, каждый риск — с мерой

14–15.10 · сделано
эталон и 12 категорий; правила и словари каталога; калибровка и порог на dev; классификатор категории; NER; UI модератора; EDA

15.10 · финальный прогон
весь holdout, отчёт v2: точность принятых 0,954, F1 0,858, спрос с заполненным атрибутом 95,7% → 97,2% → `submission/`; v1 раскрыт

16–21.10 · LLM и качество
замер с моделью организаторов на BM; ежедневные прогоны ревью с 17.10; правки по разбору ошибок — только на dev

22.10 · сдача
README с цифрами holdout, презентация, карточка решения; push в Gitea

23.10 · стоп-код
зачётное ревью репозитория, технический чекпоинт

РИСК ИЗ КЕЙСА	МЕРА	СТАТУС
Галлюцинации LLM	JSON Schema, справочники, цитата, проверка заземления, калиброванный порог; значение одной LLM — только на проверку	ЕСТЬ
Стоимость на масштабе	LLM только для слабых и упомянутых атрибутов, кэш, лимиты, on-prem: гибрид 0,83 ₽ против 5,6 ₽ за 1000 на своей GPU; дистилляция в NER	ЕСТЬ ПЛАН
Оценка не видит хвост	метрики по атрибутам, категориям, head / torso / tail, извлекаемый recall. Holdout: tail 0,818, torso 0,844 против 0,870 у head; ручной аудит эталона	ЕСТЬ ПЛАН
Дрейф, новые категории	классификатор категории (0,9998 на holdout), generic, LLM со статусом «на проверку»; `attrx monitor`: review / missing / PSI категорий → алерт	ЕСТЬ
Несправедливость к продавцам	справочник брендов всего каталога, F1 по сегментам. Holdout: партнёры 0,853 против 0,873 у М.Видео (в базовой линии 0,45 против 0,65)	ЕСТЬ

Нужно от М.Видео: официальный список обязательных атрибутов по категориям · CTR, конверсия и средний чек для оценки эффекта · выгрузка правок модераторов для петли · какой LLM-контур разрешён в проде.

План — `docs/PLAN.md`; риски и меры с путями к коду — `docs/RISKS.md`