attrx

Характеристики товара — из текста карточки. Каждое значение с цитатой и уверенностью

Гибрид для каталога М.Видео: категория по тексту, правила и словари каталога — ядро, NER — свободный текст, LLM — только подсказки модератору. Проверено на всём отложенном holdout: на нём ничего не настраивалось, слабые места раскрыты.

HOLDOUT · 23 391 КАРТОЧКА · РЕЖИМ В СДАЧЕ

0,954 точность значений, принятых в каталог автоматически
95% ДИ от 0,952; принято 94% найденного

0,937 F1 с учётом поискового спроса
micro-F1 0,858; полнота по значениям из текста 0,927

97,2% поискового спроса с заполненным атрибутом
было 95,7%: +5 488 значений там, где каталог пуст

4–7× дешевле, чем «LLM на каждую карточку»
гибрид: 0,83 ₽ на своей GPU, 20,6 ₽ в GigaChat Lite за 1000 карточек

ПРОБЛЕМА · ДЕНЬГИ

Нет характеристики — нет товара в фильтре, а значит и в выручке

56,5% кликов из поиска — по запросам, где покупатель назвал атрибут; 24,9% — характеристику кроме бренда и модели



Числа у полос — клики по точному запросу. Доли — разметка всех запросов словарём каталога; описательные запросы без значения не засчитаны — оценка снизу.

1 177 200
описаний карточек: название и текст продавца — вход решения

546 069
офферов каталога с характеристиками в 6 963 категориях — эталон

30 991 350
кликов из поиска — вес атрибута в метриках и в очереди модератора

75%
карточек без оффера и без кликов: есть только текст — холодный старт

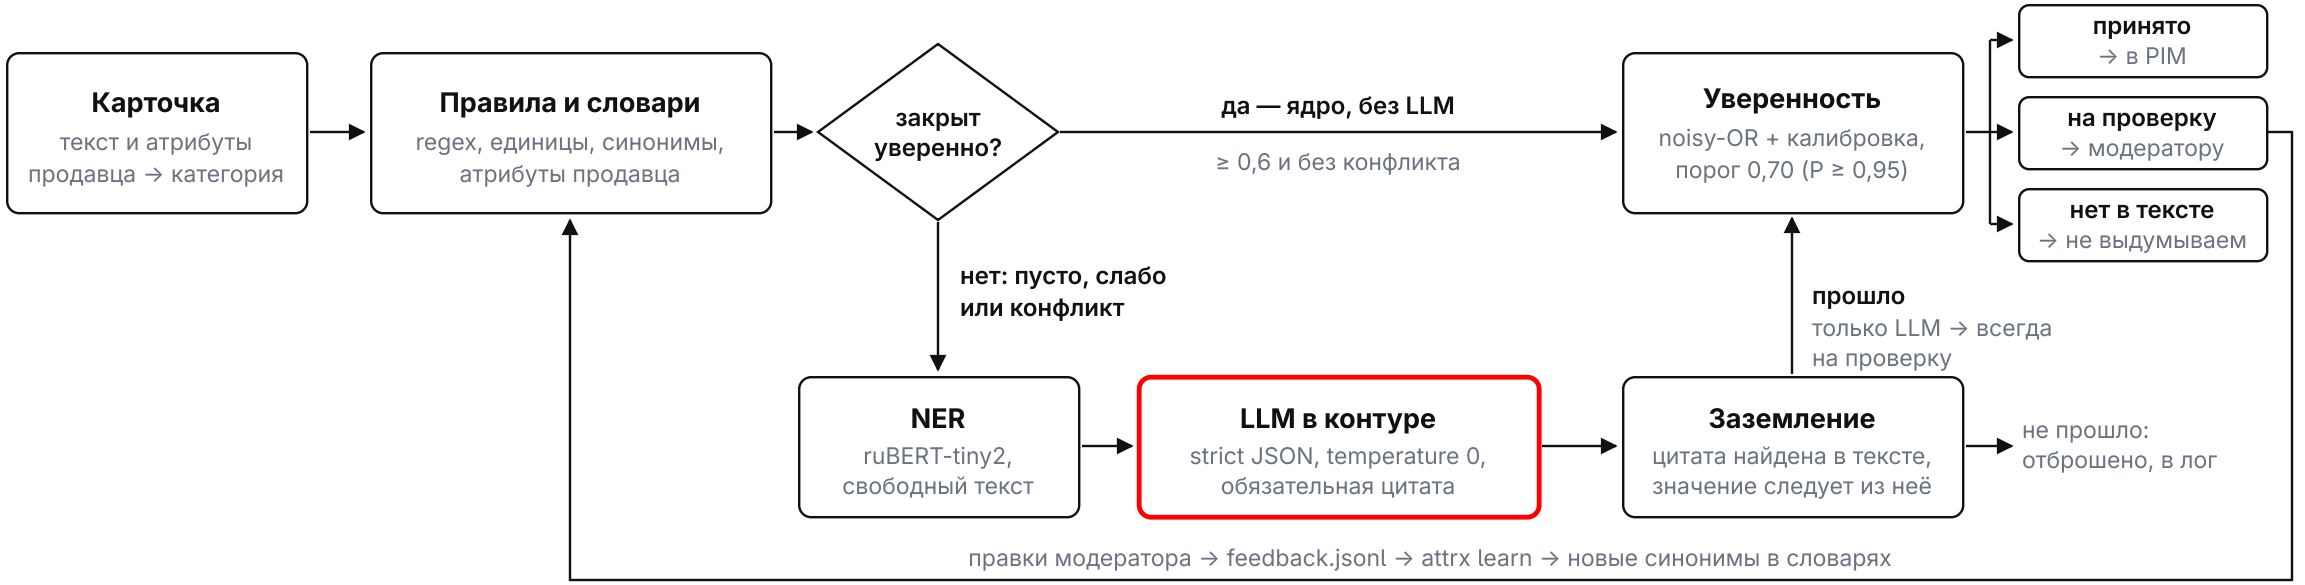
83%
эталонных значений есть в тексте карточки (holdout): остальное не извлечь, только «нет в тексте»

Деньги: дозаполненная характеристика → больше показов в фильтрах и атрибутной выдаче × CTR × конверсия × средний чек. CTR, конверсия и чек — данные М.Видео; эффект подтверждаем A/B по категориям.

Источники: архив кейса; доли спроса — `docs/EDA.md` §6; клики по запросам — `docs/checkpoint/demand_stats.json`; доля эталона в тексте — `submission/metrics.json`

РЕШЕНИЕ · ГИБРИДНЫЙ ПАЙПЛАЙН

Ядро закрывают дешёвые правила. LLM — только для остатка и только с цитатой



Категория и правила
Без id категорию даёт классификатор: 0,9998 против 0,921 у ключевых слов. Правила и 4 822 бренда каталога: F1 0,853, 1516 карточек/с на ядро.

NER
ruBERT-tiny2 на значениях каталога, найденных в тексте. Только слабые атрибуты: полнота по извлекаемому 0,918 → 0,927.

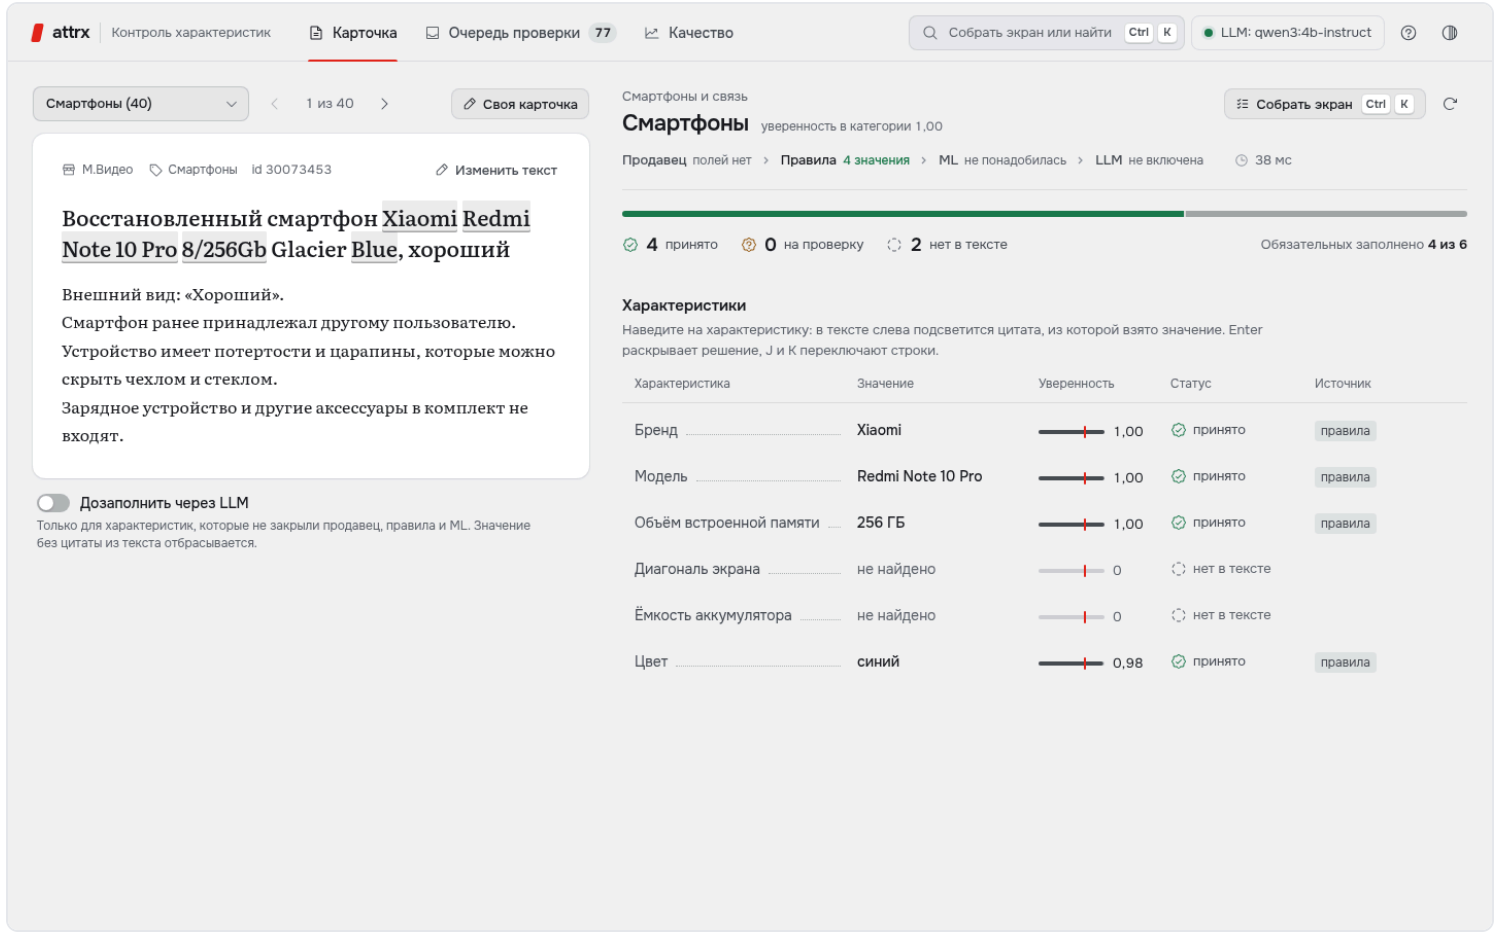
LLM
Только слабые и упомянутые в тексте атрибуты — LLM спрашивали для 31% карточек. Одна LLM — только на проверку.

Заземление и порог
Цитата найдена в тексте, значение следует из неё; калиброванный порог 0,70 → точность принятых 0,954.

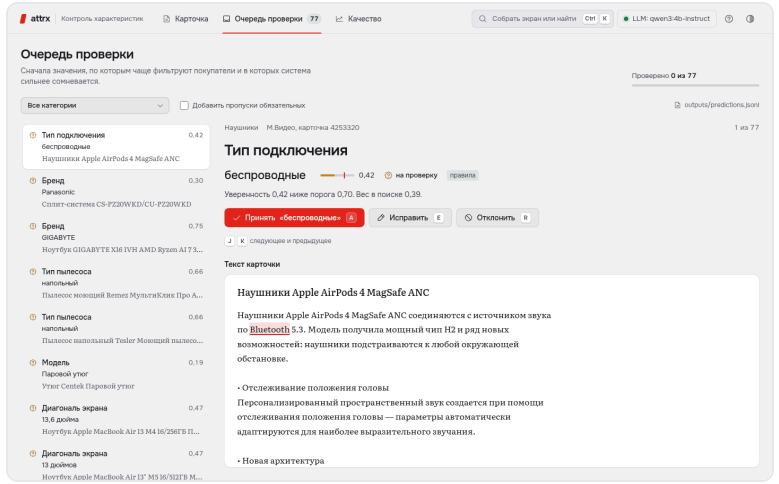
Схема = `src/attrx/pipeline.py`; классификатор — `docs/CATEGORY.md`; цифры — весь holdout, `submission/compare.json`

ЖИВОЕ ДЕМО

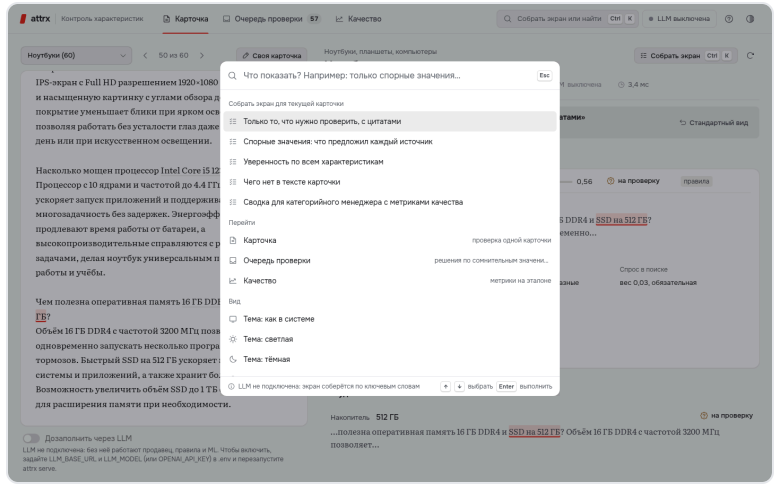
Модератор видит значение, уверенность и цитату



Карточка. Наведение на характеристику подсвечивает цитату в тексте; уверенность с отметкой порога, статус, источник, другие варианты при конфликте; «Принять / Исправить / Отклонить».



Очередь: первыми — частый спрос и низкая уверенность.



Ctrl/⌘K. Экран под запрос из безопасных компонентов.

Демо: `attrx serve` или `docker compose up` → порт 8000 на ВМ команды; Swagger — /docs; без датасета — 400 реальных карточек из `data/sample`

РЕЗУЛЬТАТ · ВЕСЬ HOLDOUT · 23 391 КАРТОЧКА

Точность принятых 0,954 — на всём holdout, на котором ничего не настраивалось

0,954

точность значений, которые attrx принял в каталог сам (цель ≥ 0,95). 95% ДИ от 0,952; принято 94% найденных значений, остальное — модератору с цитатой.

0,858

micro-F1 по всем слотам с эталоном

P 0,954 · R 0,779

0,927

полнота по значениям, которые есть в тексте

в тексте есть 83,0% эталона

0,937

F1 с учётом поискового спроса

атрибуты, по которым ищут, весят больше

95,7% → 97,2%

поискового спроса с заполненным атрибутом

слоты каталога 80,7% → 88,1%, +5 488 значений

0,019

ошибка калибровки (ECE)

у порога, 0,70–0,80, верно лишь 57% — слайд 9

10,8%

слотов уходит на проверку

цель ≤ 10% — чуть выше; на стратифицированном наборе 7,0%

Протокол. Весь holdout с эталоном без 400 SKU демо-сэмпла; 94% карточек — хвост каталога. Отчёт v2: исправления выбраны на dev, v1 раскрыт. Весь dev → весь holdout: F1 0,859 → 0,858.

Новые товары. У 72% карточек названия нет в train: F1 0,841 против 0,912 у повторов. Без category_id классификатор угадал категорию у всех 2 416 карточек стратифицированного набора.

Холодный старт. 1 000 карточек вне фида (75% каталога, эталона нет): автоматически заполнено 54,3% слотов, на проверку 11,6%.

Режим в сдаче «+ NER», порог 0,70 · `submission/metrics.json`, `REPORT.md` §1–3, §5, §11; dev — `docs/EVALUATION.md` §9.2

ЧТО ДАЁТ КАЖДЫЙ ШАГ · ТАБЛИЦА ИЗ БРИФА НА НАШИХ ЦИФРАХ

Правила дают ядро, NER — хвост, локальная LLM — ноль к F1

ПОДХОД	P	R	F1	R ПО ИЗВЛЕК.	F1 ПО СПРОСУ	MACRO-F1	ПОКРЫТИЕ	НА ПРОВЕРКУ	КАРТОЧЕК/С	LLM НА 1000
ВЕСЬ HOLDOUT · 23 391 КАРТОЧКА · ОСНОВНОЙ НАБОР										
Правила и словари	0,952	0,772	0,853	0,918	0,935	0,623	72,0%	11,2%	1 516	0
+ атрибуты продавца	0,953	0,771	0,853	0,917	0,935	0,624	71,9%	11,4%	1 454	0
+ NER — в сдаче	**0,954**	**0,779**	**0,858**	**0,927**	**0,937**	**0,640**	**73,3%**	**10,8%**	**421**	**0**
СТРАТИФИЦИРОВАННЫЙ НАБОР · 2 416 КАРТОЧЕК: ВСЕ 12 КАТЕГОРИЙ + ХВОСТ, КАК В V1										
Правила и словари	0,961	0,742	0,837	0,921	0,935	0,630	72,4%	6,8%	1 235	0
+ NER	0,961	0,749	0,842	0,930	0,937	0,646	73,4%	7,0%	382	0
+ NER без id категории (классификатор)	0,961	0,749	0,842	0,930	0,937	0,646	73,4%	7,0%	256	0
ПОДВЫБОРКА LLM · 662 КАРТОЧКИ, ВСЕ РЕЖИМЫ НА ОДНИХ И ТЕХ ЖЕ КАРТОЧКАХ										
+ NER	0,962	0,759	0,849	0,929	0,933	0,635	75,0%	6,1%	401	0
+ LLM (qwen3:4b-instruct)	0,962	0,759	0,849	0,929	0,933	0,635	75,0%	6,8%	1,0	310

Правила и словари

ядро: F1 0,853 на CPU; без справочника 4 822 брендов каталога F1 на dev ниже на 0,175 (абляция)

+ атрибуты продавца

≈ 0 на holdout: блок «Характеристики» есть лишь у 7% карточек фида; работает вне фида

+ NER

полнота 0,772 → 0,779, macro-F1 0,623 → 0,640 при той же точности

Без id категории

та же F1 0,842: классификатор угадал категорию у всех 2 416 карточек; цена — 1,3 мс на карточку

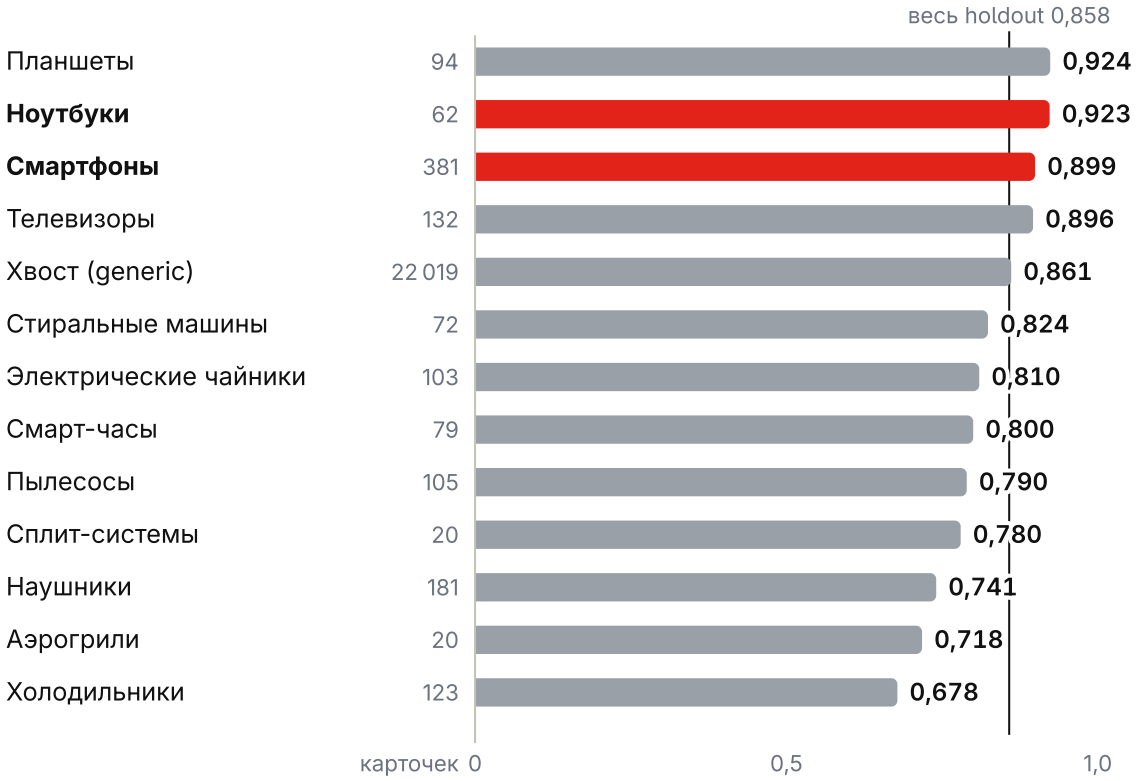
+ LLM

F1 не меняется: значения одной LLM уходят на проверку, а не в каталог — слайд 10

`submission/compare.json`, `REPORT.md` §2–4; скорость — медиана 3 замеров, NER и LLM на GPU стенда (GTX 1060); абляция — `docs/EVALUATION.md` §8.2

КАЧЕСТВО ПО КАТЕГОРИЯМ И ОБЯЗАТЕЛЬНЫМ ПОЛЯМ КЕЙСА

Ядро — 0,9 и выше; низкий F1 там, где значения нет в тексте



micro-F1 по категориям, режим в сдаче; красным — категории кейса. Холодильники и аэрогрили ниже: объём камер, высота, материал редко есть в тексте. В хвосте слабее всего цвет: F1 0,51, в тексте лишь 42% эталона.

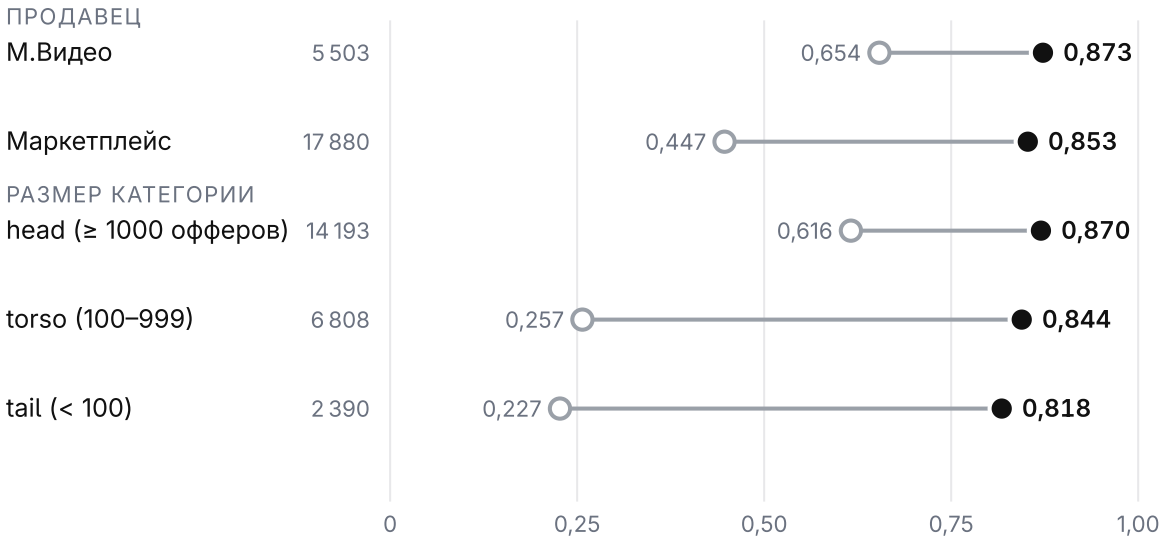
ОБЯЗАТЕЛЬНОЕ ПОЛЕ	F1	P	В ТЕКСТЕ	R ПО ИЗВЛЕК.
СМАРТФОН · 381 КАРТОЧКА				
Бренд	**1,00**	1,00	100%	1,00
Модель	**1,00**	1,00	96%	1,00
Память / накопитель	**0,99**	1,00	99%	0,99
Диагональ	**0,64**	0,98	**49%**	0,96
Аккумулятор	**0,65**	0,96	**49%**	1,00
Цвет	**0,96**	0,97	96%	0,98
НОУТБУК · 62 КАРТОЧКИ				
Бренд	**0,98**	0,98	100%	0,98
Процессор	**0,89**	0,95	95%	0,85
Оперативная память	**0,92**	0,93	95%	0,95
Память / накопитель	**0,92**	0,95	95%	0,95
Диагональ	**0,91**	0,98	89%	0,95
Цвет	**0,90**	0,96	85%	1,00

Диагональ и аккумулятор смартфона есть в тексте у половины карточек: полнота по ним 0,96–1,00, общий F1 ограничен текстом.

`submission/metrics.json` (`per_category`), `REPORT.md` §6–7 · «в тексте» — доля эталонных значений, которые вообще есть в тексте карточки

СПРАВЕДЛИВОСТЬ · ПРОДАВЦЫ, ХВОСТ КАТАЛОГА, НОВЫЕ ТОВАРЫ

Партнёры маркетплейса и редкие категории — на уровне М.Видео и крупных



F1 по сегментам. ○ база: dev (стратифицированный набор), продавец + правила до словарей каталога · ● весь holdout, режим в сдаче. Справа от названия — карточек на holdout.

2,0 п.п.
разрыв М.Видео и маркетплейса (цель ≤ 5; в базе — 21 п.п.): справочник 4 822 брендов всего каталога одинаково покрывает всех продавцов

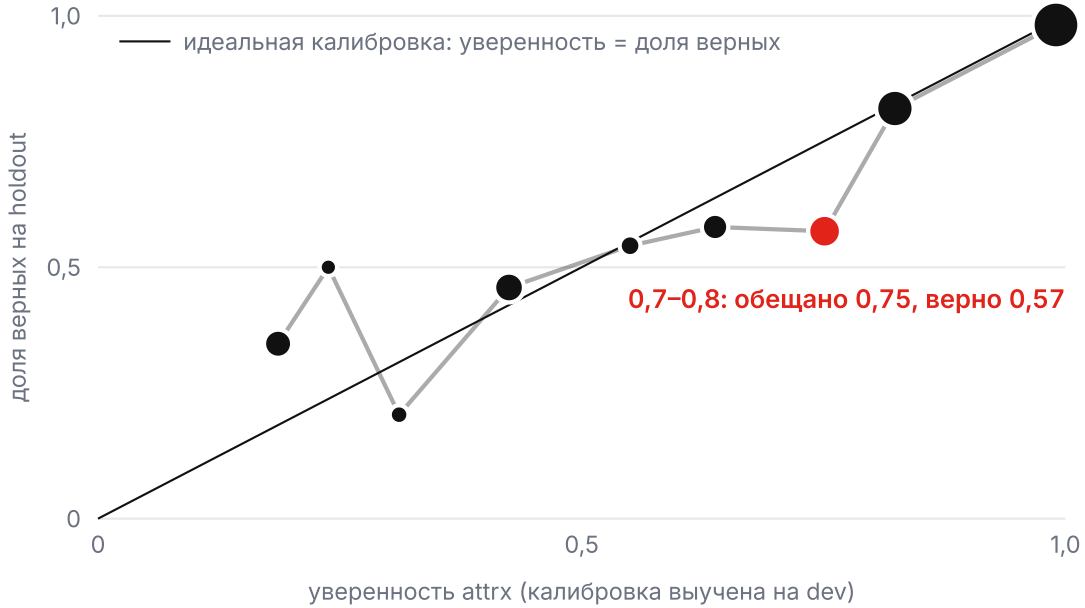
5,2 п.п.
разрыв крупных и редких категорий (цель ≤ 10): у tail точность 0,933 против 0,962, полнота по извлекаемому 0,893 против 0,942

0,857 · 0,853 · 0,881
короткие, средние и длинные описания; полнота по извлекаемому 0,924 · 0,924 · 0,941

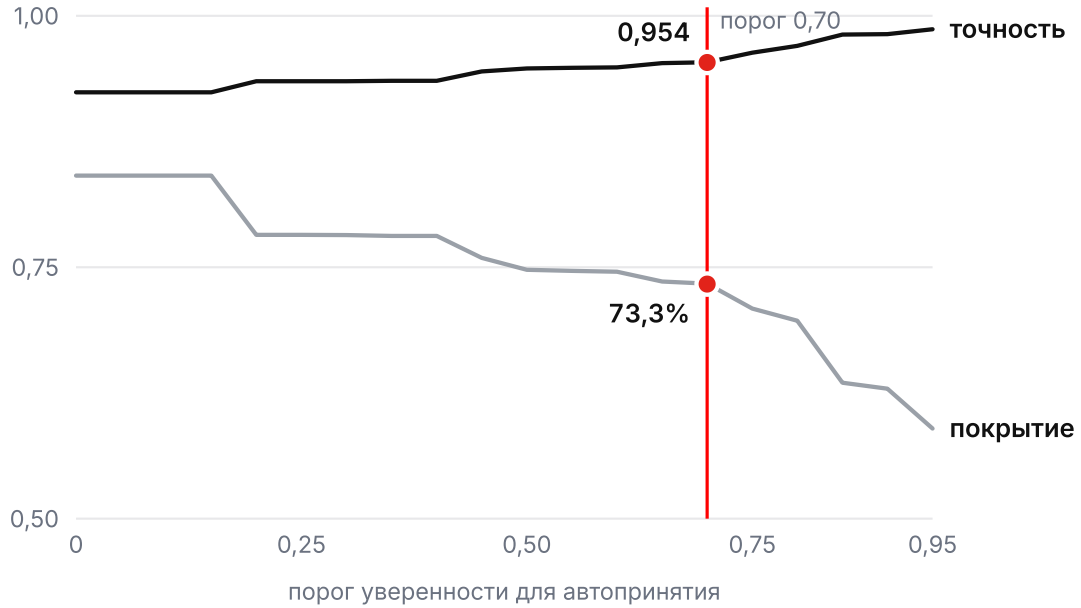
0,841 против 0,912
новые названия (нет в train, 16 803 карточек) против повторов; полнота по извлекаемому почти та же: 0,922 против 0,941

holdout — `submission/segments.json`, `REPORT.md` §5, §8; база — `docs/EVALUATION.md` §8.4 (dev); head / torso / tail — число офферов в листовой категории

Точность принятых 0,954 выдержала holdout, но у самого порога уверенность завышена



ECE 0,019 на 52 134 значениях с эталоном. 84% значений — в корзине 0,9–1,0: уверенность 0,990, верно 0,982. Размер точки — число значений.



Порог 0,70 выбран на dev: наименьший, при котором нижняя граница точности принятых ≥ 0,95 и ни одна ячейка не ниже 0,75; на dev кросс-фиттингом ожидали 0,967. На holdout не подбирался: 0,954 (ДИ от 0,952), принято 94% найденного.

Слабое место. Принятые значения с уверенностью 0,70–0,80 верны лишь в 57% случаев: 2 008 значений — 4% принятого, но 38% ошибок среди принятого; 91% из них — цвет и модель хвоста. На dev картина та же. Кандидат исправления найден только на dev: калибровка на всём dev → порог 0,82, точность принятых 0,982 при доле автопринятия 85,5% вместо 94%. **Не применён:** выбор после просмотра holdout нарушил бы протокол; решение — по мониторингу на новых данных.

LLM · ЧЕСТНЫЙ РЕЗУЛЬТАТ

С локальной 4B-моделью LLM — подсказка модератору, а не автоматический источник

31% карточек подвыборки (662), где LLM вообще спросили

205 вызовов: только слабые и упомянутые в тексте атрибуты; 969 + 52 токена, 3,3 с на вызов (p95 5,0 с), ошибок 0

61 ответ без опоры в тексте — отброшен проверкой заземления

цитаты нет в карточке или значение из неё не следует

71 значение предложила только LLM — ушло модератору, а не в каталог

из них 23 закрывают слот, пустой без LLM

38% верны там, где есть эталон (13 из 34)

поэтому одна LLM не решает: правило `pipeline.UNVERIFIED_ONLY`

ПОДВЫБОРКА, 662 КАРТОЧКИ	P	R	F1
+ NER, без LLM	0,962	0,759	0,849
+ LLM, одна LLM → проверка (в сдаче)	0,962	0,759	0,849
+ LLM, если принимать одну LLM автоматически	**0,958**	0,762	0,849

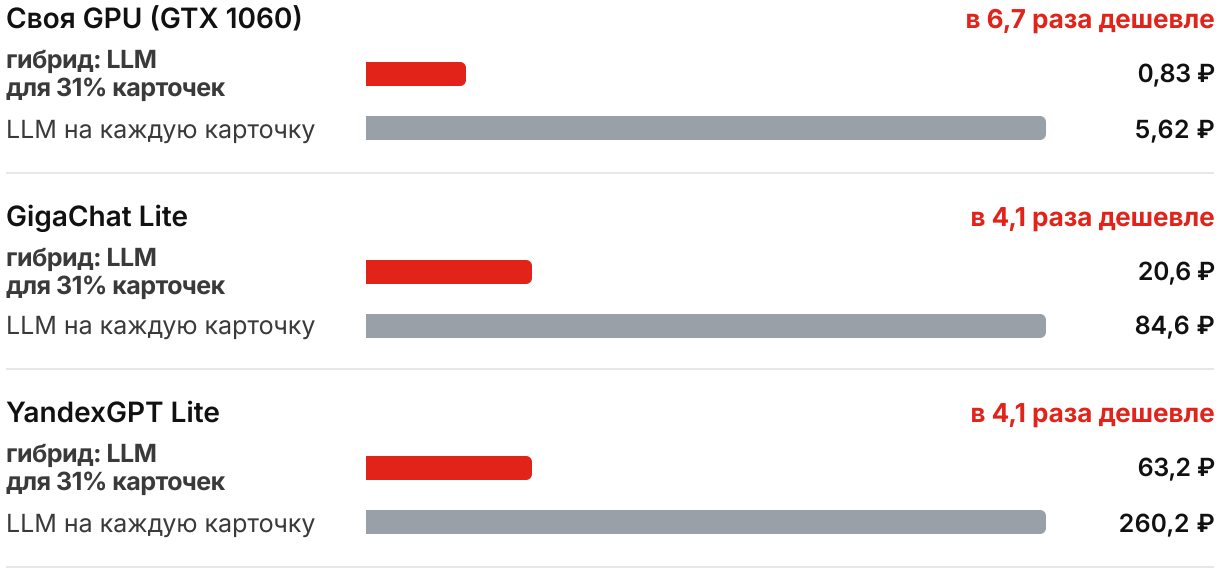
Вывод. Автопринятие ответов 4B-модели добавило бы 0,003 полноты ценой 0,004 точности каталога. Правила + NER закрывают ядро и хвост; LLM — подсказки модератору с цитатой. **Следующий шаг:** тот же замер с моделью организаторов на BM (`make report`) и 7–8B в vLLM — порог и правило доверия не меняются.

`submission/REPORT.md` §4, `compare.json` (набор `llm_subsample`); модель — qwen3:4b-instruct в Ollama на GTX 1060, кэш ответов выключен

ЭКОНОМИКА

Гибрид в 4–7 раз дешевле «LLM на каждую карточку», режим в сдаче — почти бесплатен

₽ ЗА 1000 КАРТОЧЕК · ПОЛОСЫ — ВНУТРИ СТРОКИ



СКОРОСТЬ И СТОИМОСТЬ РЕЖИМОВ НА СТЕНДЕ КОМАНДЫ

РЕЖИМ	НА КАРТОЧКУ	₽ ЗА 1000	С LLM
Правила и словари	0,7 мс	< 0,01 ₽	0%
+ атрибуты продавца	0,7 мс	< 0,01 ₽	0%
+ NER — в сдаче (GPU)	**2,4 мс**	**< 0,01 ₽**	**0%**
+ LLM: гибрид, своя GPU	1,0 с	0,83 ₽	31%
LLM на каждую карточку	6,9 с	5,62 ₽	100%

Время — медиана 3 замеров на всём holdout. Свой стенд — GTX 1060: 2,93 ₽/ч (амортизация + электричество) × время пайплайна. API — тарифы с НДС на 14.10.2026 и токены замера (969 + 52 на вызов). «LLM на каждую» — бенчмарк `attrx llm-bench`: все атрибуты, 6,9 с на карточку.

`submission/cost.json`, `REPORT.md` §12, `config/llm_prices.yaml`, `docs/LLM.md` §6; провайдеры API — оценка по токенам замера

В прод — через тень; каждый риск кейса закрыт мерой и измерен

0 · Офлайн-гейт
точность принятых ≥ 0,95: на всём holdout 0,954; разрывы 2,0 и 5,2 п.п. — выполнено

1 · Тень, 2–4 недели
пишем рядом, не в каталог; сверяем с модераторами; слой 0,70–0,80 — на аудит, решаем о новой калибровке

2 · Автопринятие
выше порога — в PIM в топ-категориях по трафику; выборочный аудит; точность ниже гейта — категория обратно в тень

3 · Все категории
холодный старт: LLM-подсказки на проверку, правки → словари и NER

Интеграция
`POST /api/extract/batch` (до 1000) или `attrx extract`; LLM — vLLM / Ollama в контуре, без VPN

РИСК	МЕРА В РЕШЕНИИ	ЧТО ПОКАЗАЛ HOLDOUT
Галлюцинации LLM	схема, справочник, цитата и проверка заземления, калиброванный порог; значение одной LLM — только на проверку	**61 ответ без опоры отброшен; 71 значение одной LLM — модератору (верны 38%)**
Стоимость на масштабе	LLM только для слабых и упомянутых атрибутов, кэш, лимиты, on-prem	**гибрид в 4–7 раз дешевле; режим в сдаче — < 0,01 ₽ за 1000 карточек**
Оценка не видит хвост	весь holdout, метрики по атрибуту и категории, head / torso / tail, полнота по извлекаемому	**tail 0,818, torso 0,844; 77% пропусков — значения нет в тексте**
Дрейф, новые категории	классификатор категории, generic-схема, таксономия в YAML; `attrx monitor`: review, missing, PSI категорий → алерт	**без category_id категория угадана у всех 2 416 карточек; вне фида 54,3% слотов автоматически**
Несправедливость к продавцам	справочник брендов всего каталога, метрики по сегментам	**маркетплейс 0,853 против 0,873 у М.Видео (было 0,447 против 0,654)**
Калибровка у порога	нашли сами; аудит слоя 0,70–0,80 в тени; кандидат — калибровка на всём dev (порог 0,82)	**слой верен на 57%: 4% принятого, 38% ошибок; весь поток — 0,954**

docs/DEPLOYMENT.md, docs/RISKS.md, docs/MONITORING.md, submission/REPORT.md §9, §13

ИТОГ

Каталог полнее, точность принятого ≥ 0,95, LLM — только под контролем

Что сдано

Код и пайплайн — пакет `attrx`, CLI, API, Docker

README — запуск за 5 минут, матрица «требование → где»

EDA — `notebooks/01_eda.ipynb`, `docs/EDA.md`

Предсказания по каждой карточке — `submission/predictions.*`

Отчёт и метрики — `submission/REPORT.md`, проверка цифр — `make verify`

Презентация — этот файл, `docs/slides.pdf`

Что получает М.Видео

0,954 — точность значений, которые попадают в каталог без человека

95,7% → 97,2% — доля спроса с заполненным атрибутом; +5 488 значений на holdout

54,3% слотов заполняется автоматически у карточек вне фида (75% каталога)

10,8% слотов — модератору, с цитатой и в порядке спроса

0,83 ₽ за 1000 карточек с LLM на своей GPU; без LLM — меньше копейки

Следующий шаг

Пилот в тени на одной категории: смартфоны или телевизоры

Калибровка: кандидат с dev (порог 0,82, точность принятых 0,982 при 85,5% автопринятия) — включаем по данным тени

LLM: замер с моделью организаторов на BM и 7–8B в vLLM

От М.Видео: список обязательных атрибутов, CTR / конверсия / чек для A/B, выгрузка правок модераторов, разрешённый LLM-контур