attrx

ИИ для автоматического заполнения характеристик товаров

Гибридный пайплайн «правила → ML → LLM» с уверенностью, цитатами и generative UI для модератора

Кейс М.Видео №3 · NLP и e-commerce · команда jasperBLCK + Makhkets

attrx

Проблема

- Карточки от продавцов шумные: характеристики в свободном тексте, разные единицы и синонимы
- Не заполнен атрибут → товара нет в фильтре → ниже CTR и конверсия
- Ручное заполнение медленное и дорогое, а ошибки попадают в поиск

Цель: заполнить обязательные атрибуты автоматически и ничего не выдумать

attrx

Решение

Карточка → **Категория** → **Продавец** → **Правила** → **NER** → **LLM** → **Проверка цитаты** → **Уверенность** → **accepted / review / missing**

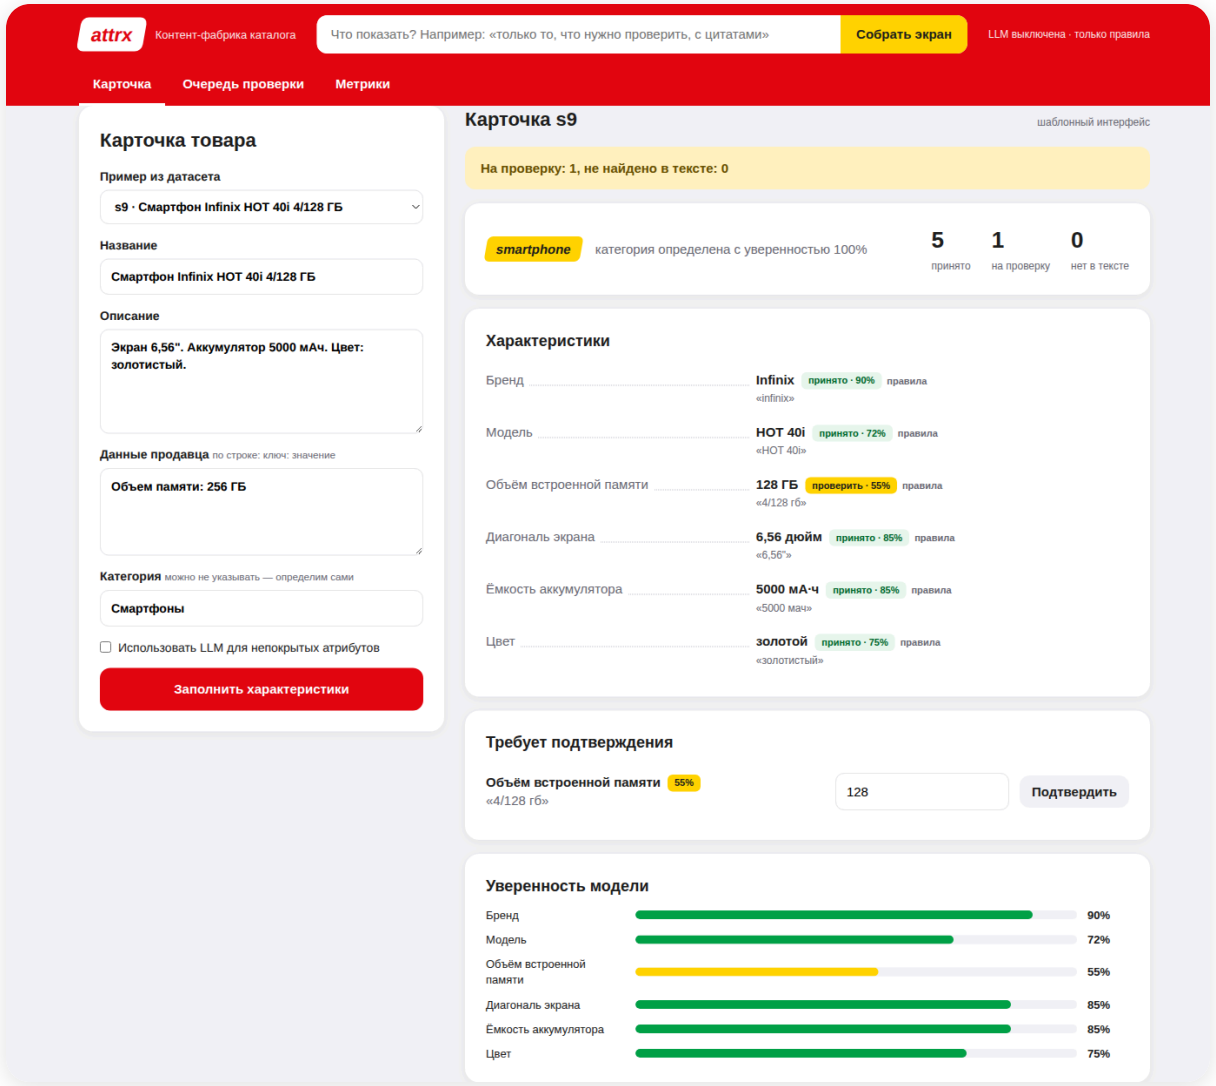
- Дешёвые источники закрывают ядро, модели работают только на хвосте
- У каждого значения есть уверенность, источник и цитата из карточки
- Сомнительные значения уходят модератору, его правки пополняют словари

attrx

Анти-галлюцинации

- LLM обязана вернуть дословную цитату (strict JSON schema)
- Проверка заземления: цитата есть в карточке, значение из неё следует, enum-значение есть в справочнике
- Конфликт продавца и текста → статус review, альтернативы показываются модератору
- Generative UI: модель выбирает компоненты, значения берутся из результата, а не из её ответа

Generative UI



Интерфейс собирается под запрос модератора: «покажи только то, что надо проверить, с цитатами».

LLM возвращает декларативный UISpec из 7 разрешённых компонентов. Его валидирует pydantic, рендер идёт без innerHTML.

Без LLM работает детерминированный шаблон.

attrx

Сравнение подходов

Режим	Precision	Recall	F1	Coverage	Карт/с	LLM
правила	1.000	0.933	0.965	0.866	761.7	0
продавец + правила	1.000	0.990	0.995	0.920	1137.3	0
+ ML (NER)	1.000	0.990	0.995	0.920	30.0	0

Данные: синтетический sample (20 карточек), правила отлаживались на нём. Это проверка пайплайна, а не оценка качества. Таблицу перегенерирует attrx report на holdout организаторов.

attrx

Метрики, которые мы считаем

- Precision / Recall / F1 по каждому атрибуту и категории
- Coverage: доля заполненных атрибутов
- Traffic-weighted F1: важнее атрибуты, по которым фильтруют
- Кривая precision/coverage от порога → выбор CONFIDENCE_THRESHOLD под целевую точность
- Качество по сегментам продавцов

Сегмент	Карточек	F1	Coverage
есть атрибуты продавца	16	0.994	0.935
нет атрибутов продавца	4	1.000	0.850
короткое описание (<80 симв.)	18	0.995	0.920
длинное описание (>=80 симв.)	2	1.000	0.917

attrx

Внедрение без VPN

- Без LLM всё работает на правилах и NER на CPU: один Docker-контейнер
- LLM через любой OpenAI-совместимый endpoint: on-prem vLLM/Ollama, GigaChat, YandexGPT
- Кэш и лимит вызовов: LLM платим только за хвост
- Интеграция: POST /api/extract/batch из PIM или CLI по выгрузке

attrx

Риски

Риск	Мера
Галлюцинации LLM	цитата + заземление + порог
Стоимость	гибридный роутинг, кэш, локальная модель
Eval не покрывает хвост	holdout, метрики по категориям и сегментам
Дрейф и новые категории	таксономия в YAML, LLM для cold-start, петля фидбэка
Несправедливость к продавцам	coverage по сегментам, заполнение из текста

attrx

Дальше

- Дообучить NER на gold организаторов, active learning на очереди review
- LLM-предразметка (attrx prelabel) → человек проверяет → новые обучающие данные
- Мониторинг качества по категориям в проде